

Métricas de Evaluación en Aprendizaje Supervisado

En esta presentación se estudia cómo medir el rendimiento de un modelo supervisado. Se detallarán diferentes métricas según el tipo de problema y aplicaremos las métricas correctamente.

Jaime Alberto Guzman Luna, Ph.D



Todos los Modelos Cometen Errores

Sobreaajuste (overfitting) = Bajo sesgo, alta varianza

Aprende demasiado bien el entrenamiento, pero generaliza mal.

Subajuste (underfitting) = Alto sesgo, baja varianza


No aprende ni siquiera del entrenamiento, bajo desempeño en todo.



No Free Lunch Theorem

No existe un modelo de aprendizaje ni métrica que funcione mejor para todos los problemas.


- Cada problema requiere un análisis particular.
- Por eso, es clave entender **qué errores estamos dispuestos a tolerar y qué métricas son prioritarias** según el contexto.



Matriz de Confusión

La **matriz de confusión** es una herramienta fundamental en aprendizaje automático para **evaluar el desempeño de un modelo de clasificación**. Muestra de forma tabular cuántas predicciones hizo correctamente y cuántas se equivocó, diferenciando entre los distintos tipos de errores.

Para un problema de **clasificación binaria** (dos clases: positiva y negativa), la matriz tiene esta forma:



- **Verdaderos Positivos (True Positives o TP)**: son los ejemplos que han sido marcados de manera correcta como pertenecientes a la clase A.
- **Falsos Positivos (False Positives o FP)**: serán los ejemplos marcados como de clase A, pero en realidad no pertenecen a ella, es decir, han sido clasificados de manera incorrecta.
- **Verdaderos Negativos (True Negatives o TN)**: en este caso, los ejemplos NO son de la clase A y han sido clasificados como correctos (No de la clase A).
- **Falsos Negativos (False Negatives o FN)**: en este grupo estarán los ejemplos marcados como NO pertenecientes a la clase A, pero en realidad sí lo son y, por tanto, no se han clasificado correctamente.



Métrica 1 – Accuracy (exactitud)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FN + FP}$$

1

Interpretación

Representa la razón entre las predicciones correctas sobre el total de predicciones realizadas.

2

Problema

En **datos desbalanceados**, da falsa sensación de buen rendimiento.

3

Ejemplo

Conjunto con 95% de clase negativa, el modelo siempre predice “negativo” y tendrá 95% de accuracy, **pero no sirve**.

El ***accuracy*** es una métrica sencilla e intuitiva, pero su utilidad se ve limitada cuando las clases están **desbalanceadas**. En estos casos, es necesario considerar otras métricas que proporcionen una visión más completa del rendimiento del modelo.

Métrica 2 – PRECISION

$$\text{Precision} = \frac{TP}{TP + FP}$$

1

Interpretación

De todas las veces que el modelo dijo "positivo", ¿cuántas veces acertó?.
Mide la proporción de identificaciones positivas que son realmente correctas.

2

Cuándo es importante

Cuando **minimizar** los **falsos positivos** es crucial.

- La *precision* se enfoca en la **exactitud** de las **predicciones positivas**. Un modelo con alta precisión es confiable al predecir la clase positiva, minimizando los errores de falsos positivos.
- Nota:** Su valor aumenta a medida que el número de falsos positivos disminuye



Métrica 3 – RECALL (Exhaustividad)

$$\text{Recall} = \frac{TP}{TP + FN}$$

1

Interpretación


De todos los positivos reales, ¿cuántos detectó el modelo?

2

Cuándo es importante

Cuando **minimizar** los **falsos negativos** es primordial.

El *recall* se centra en la capacidad del modelo para identificar todos los **casos positivos reales**. Un modelo con alto *recall* es sensible a la clase positiva, minimizando los errores de falsos negativos.



Métrica 4 – F1-SCORE

1

Interpretación

Media armónica entre precisión y recall.

2

Cuándo es importante


Útil cuando se quiere un balance entre ambos

Valores:

1: Modelo perfecto (perfecto recall y precision)

0: Modelo pésimo (al menos una métrica es mala)

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$




$$F1 \text{ Score} = \frac{2 * (\checkmark \text{ True Positives})}{2 * (\checkmark \text{ True Positives}) + (X \text{ False Positives}) + (\checkmark \text{ False Negatives})}$$


El ***F1-score*** es una métrica que combina la **precisión** y el ***recall*** en un solo valor, proporcionando una evaluación más equilibrada del rendimiento del modelo, especialmente en **conjuntos de datos desbalanceados**.

Curva Precisión-Recall

- La **curva Precision-Recall** es una herramienta fundamental para evaluar modelos de clasificación.
- Permite visualizar cómo al aumentar una medición (**recall**), típicamente disminuye la otra (**Precisión**).
- Se usa principalmente cuando: (i) **Datasets desbalanceados**; (ii) Cuando los falsos negativos son muy costosos (ejemplo en situaciones donde "no detectar un positivo" tiene consecuencias graves como el tema de detección de cancer.); (iii) Cuando te importa más la clase minoritaria
- Interpretación:** Se enfoca en "de los casos que predije como positivos, ¿cuántos realmente lo eran?" y "de todos los casos positivos, ¿cuántos detecté?"




¿Cómo luce el algoritmo perfecto?




Comparación de modelos

Cual clasificador es mejor? A o B?




Cual clasificador es mejor? A o C?




Comparación de modelos

Cual clasificador es mejor? A o C?



Curva ROC y AUC

Las curvas ROC (Receiver Operating Characteristic) son una herramienta fundamental para evaluar modelos de clasificación binaria (uso común).



Curva ROC

- La curva ROC se enfoca en "¿qué tan bien separo las clases positivas y negativas?".
- La curva ROC gráfica:
 - Eje y: tasa de verdaderos positivos (TPR = recall).
 $TPR = VP / (VP + FN)$
 - Eje x: tasa de falsos positivos (FPR).
 $FPR = FP / (FP + VN)$
- Permite evaluar y comparar modelos:
 - El AUC-ROC (área bajo la curva) resume el rendimiento en un solo número
 - AUC = 1.0: modelo perfecto.
 - AUC = 0.5: modelo aleatorio
 - AUC < 0.5: modelo peor que aleatorio



Curva ROC y AUC

• Para qué sirven?

- Evaluar rendimiento del modelo (ya visto)
- Comparar múltiples modelos: Puedes superponer varias curvas ROC para ver cuál funciona mejor globalmente.




¿Cuándo usar ROC?

- Funciona bien cuando:
 - Dataset está balanceado (clases similares en tamaño)
 - Ambos errores (FP y FN) tienen costos similares
 - Quieres evaluar rendimiento general del modelo
- No es ideal cuando:
 - Dataset muy desbalanceado (ahí es mejor Precision-Recall)
 - Los falsos negativos son mucho más costosos que los falsos positivos



CLASIFICACIÓN MULTICLASE

¿Cómo adaptamos las métricas binarias?



One-vs-Rest (OvR):

- Se analiza **una clase a la vez** como si fuera “positiva” y el resto como “negativas”.
- Así se puede aplicar precision, recall, F1, ROC, AUC para **cada clase por separado**.

Luego se combinan los resultados con promedios.



Promedios:

- Macro:** calcula la métrica individualmente por clase y promedia.
 - Suma TODOS los TP,
 - TODOS los FP,
 - TODOS los FN,
 - y luego calcula una única métrica global.
- Weighted:** como macro, pero ponderando por cantidad de muestras por clase (support).



Curva ROC

También se puede adaptar usando **One-vs-Rest**:

- Se construye una curva ROC **para cada clase**, comparando esa clase contra todas las demás.
- Luego se puede:
 - Mostrar varias curvas (una por clase)
 - Calcular un **promedio AUC** general

Animal		Barn owl
		Chihuahua
		Sheep dog
Not animal		Apple
		Muffin
		Mop



Actual

		Predicted	
		Animal	Not animal
Actual	Animal	True Positives	False Negatives
	Not animal	False Positives	True Negatives




		Predicted	
		Animal	Not animal
Actual	Animal	 	
	Not animal	 	
		True Positives	3
		True Negatives	3
		False Positives	0
		False Negatives	0

Confusion matrix with perfect predictions



		Predicted	
		Animal	Not animal
Actual	Animal	 	
	Not animal	 	
		True Positives	2
		True Negatives	2
		False Positives	1
		False Negatives	1

Confusion matrix with imperfect predictions



Recomendaciones de Métricas

La elección de métricas depende del problema. Cada escenario tiene sus propias prioridades.

Condición del problema o datos	Métricas recomendadas	Motivo / Justificación
Clases balanceadas	Accuracy, F1	Todas las clases tienen peso similar. Accuracy es representativa.
Clases desbalanceadas	F1, Recall, Precision, AUC	Accuracy puede ser engañosa; se necesitan métricas por clase.
Pocos falsos negativos tolerables	Recall	Es preferible detectar todos los positivos.
Pocos falsos positivos tolerables	Precision	Es preferible acertar en los positivos aunque se omitan algunos.
Interés en rendimiento general por clase	Macro F1, Balanced Accuracy	Mide rendimiento individual por clase sin sesgo hacia clases grandes.
Clases con tamaños muy distintos	Weighted F1, ROC AUC OvR	Pondera según el tamaño real de cada clase.
Necesidad de comparar modelos independientemente del umbral	AUC-ROC, PR Curve	Evalúan el modelo en todos los umbrales posibles.
Problema multiclase	F1, AUC One-vs-Rest (OvR)	Múltiples clases.
Alta variabilidad en desempeño entre clases	Matriz de confusión, métricas por clase	Permite análisis detallado de fortalezas y debilidades del modelo.



Ejemplos Prácticos de Aplicación: Detalles



🔍 Métricas

Se detalla el cálculo de las siguientes métricas en el marco del clasificador SVM (**SVC**):

- Accuracy (Exactitud)
- Precision (Precisión)
- Recall (Exhaustividad o sensibilidad)
- F1-score

[6-01-Metricas.ipynb](#)

📈 Curvas

Se detalla la creación de las curvas **recall vs precisión** y las curvas **ROC-AUC**.

[6-02-Curvas.ipynb](#)