



K-Means

En esta presentación se detalla el algoritmo K-Means: qué es, cómo funciona y por qué es relevante en Inteligencia Artificial. Se explora su lógica paso a paso y cómo permite agrupar datos de manera automática para descubrir patrones ocultos sin necesidad de supervisión.

Jaime Alberto Guzman Luna, Ph.D



¿Qué es K-Means?

K-Means es un algoritmo de **clustering** o agrupamiento utilizado en **aprendizaje automático** para dividir un conjunto de datos en **K** grupos o clusters distintos.

El objetivo es que los puntos de datos dentro de un mismo cluster sean lo más similares posible entre sí, y lo más diferentes posibles de los puntos en otros clusters. La similitud se mide típicamente utilizando la **distancia euclidiana**.

Agrupamiento

K-Means agrupa datos en clusters basados en similitud, ideal para segmentación y reconocimiento de patrones.


Simplicidad

El algoritmo es fácil de entender e implementar, lo que lo hace accesible para muchos usuarios.


Escalabilidad

K-Means puede manejar grandes conjuntos de datos eficientemente, lo que lo hace útil en diversas aplicaciones.

K-Mean clustering



¿Cómo funciona el algoritmo K-Means?



El algoritmo K-Means sigue un proceso iterativo que busca dividir un conjunto de datos en **K** clusters distintos.

1. Inicialización

Se seleccionan **K** centroides iniciales, ya sea de manera aleatoria o mediante técnicas como **K-Means++** para mejorar la inicialización.

2. Asignación

Cada punto de datos se asigna al centroide más cercano, formando así **K** clusters. La cercanía se mide mediante la **distancia euclidiana**.

3. Recálculo

Se recalculan los centroides, siendo cada **nuevo centroide** el promedio de todos los puntos en su cluster respectivo.

Los pasos 2 y 3 se repiten hasta que los centroides ya no cambian significativamente, alcanzando la **convergencia**.

Formulas

Distancia Euclidiana :

Si tienes dos vectores:

$$\mathbf{p} = (p_1, p_2, \dots, p_n), \quad \mathbf{q} = (q_1, q_2, \dots, q_n)$$

Entonces:

$$\text{Distancia Euclidiana} = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Cálculo de centroide :

Supón que tienes un clúster C_j con los puntos $\{x^{(1)}, x^{(2)}, \dots, x^{(m_j)}\}$

Entonces el centroide μ_j del clúster C_j se calcula como:

$$\mu_j = \frac{1}{m_j} \sum_{i=1}^{m_j} x^{(i)}$$

Es decir, es el **promedio vectorial** de todos los puntos del clúster.



Mejores prácticas y consejos

Para aprovechar al máximo el algoritmo K-Means, es importante seguir algunas mejores prácticas y aplicar técnicas que ayuden a optimizar y evaluar el proceso de clustering.

Selección del valor de K

Para determinar el número adecuado de clusters (**K**) existen dos métodos:

- El **método del codo**
- El **análisis de la silueta**.

Preprocesamiento de datos

El preprocesamiento de los datos es fundamental para el éxito de K-Means, incluyendo **normalización** y **eliminación de outliers**.

Evaluación de resultados

Es importante evaluar la calidad del clustering obtenido mediante métricas como **SSE** y el **coeficiente de Silhouette**.



Selección del valor de K: Método del codo

Entrenar

Entrenas el sistema K-Means con diferentes valores de **K**

Calcular SSE (INERTIA)

Representa qué tan bien se ajustan los puntos de datos a sus respectivos grupos.

Se calcula la suma de los errores al cuadrado (**SSE**) para cada K.

$$SSE(K) = \sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2$$


- x : cada punto de dato del centroide i (C_i)
- μ_i : el centroide del clúster al que pertenece x
- K : número de clústers

Observar Gráfica

Graficar la Inertia (SEE) en función de K.

Identificar el punto donde la curva deja de decrecer bruscamente → ese punto es el **codo**.

El Método del codo implica ejecutar K-Means para diferentes valores de **K** y calcular la *suma de los errores al cuadrado* (SSE) para cada valor.



Selección del valor de K: Silhouette Score

Evalúa: (i) ¿Qué tan parecido es un punto a los elementos de su propio cluster? y (ii) ¿Qué tan diferente está de los otros clusters?.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$ = distancia promedio a los otros puntos del mismo cluster.
- $b(i)$ = distancia promedio al cluster más cercano.



S(i) cercano a 1 → excelente agrupamiento.

s(i) cercano a 0 → en frontera entre clusters.

s(i) negativo → mal agrupado.





Técnicas que mejoran o ayudan al K-Means

K-Means++

Mejora la inicialización de centroides en K-Means eligiendo el primero al azar y los siguientes basados en la distancia mínima al cuadrado. Reduce el riesgo de malos agrupamientos

Fórmula de probabilidad:
$$P(x) = \frac{D(x)^2}{\sum D(x')^2}$$

- $D(x)$: distancia del punto x al centroide más cercano ya seleccionado
- suma total de todas las distancias al cuadrado.

Permite que los puntos más alejados de los centroides actuales tengan mayor probabilidad de ser elegidos ($D(x)^2$). Esto ayuda a dispersar los centroides iniciales.

Pasos:

1. Elegir el primer centroide al azar entre los puntos de datos.
2. Para cada punto x , calcular la distancia al centroide más cercano ya elegido.
3. Elegir el siguiente centroide con probabilidad proporcional al cuadrado de esa distancia $D(x)^2$
4. Repetir hasta seleccionar k centroides.
5. Ejecutar K-Means estándar con esos centroides iniciales.



Técnicas que mejoran o ayudan al K-Means

Escalado de Datos

Evita que variables en distinta escala distorsionen la distancia Euclidiana, normalizando o reescalando los datos. Fórmula de Min-Max Scaling:


$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Ventajas y limitaciones de K-Means

K-Means ofrece varias ventajas, sin embargo, también presenta limitaciones importantes que deben tenerse en cuenta.

Ventajas

- Simplicidad: fácil de entender e implementar.
- Rapidez: eficiente en términos computacionales.
- Escalabilidad: Funciona bien con grandes conjuntos de datos.



Limitaciones

- Sensibilidad a la inicialización: diferentes inicializaciones pueden conducir a diferentes resultados.
- Requiere especificar el número de clusters (**K**) previamente.
- No maneja bien clusters de formas irregulares o de tamaños muy diferentes.

Conclusión



El algoritmo K-Means es una herramienta para el **clustering** de datos en el ámbito del **aprendizaje automático** y la **minería de datos**.

Su eficacia depende en gran medida de la elección adecuada del número de clusters (**K**), la correcta inicialización de centroides, y el preprocesamiento adecuado de los datos.

Con una implementación cuidadosa y siguiendo las mejores prácticas, K-Means puede ofrecer resultados valiosos y permitirte descubrir patrones ocultos en los datos.





Ejemplo Práctico de Aplicación: Detalles



Q Dominio

Se usa el **Wine Dataset** de sklearn. Es un conjunto de datos del campo de la química analítica, que contiene información sobre el contenido químico de vinos provenientes de tres cultivos diferentes de uvas.

Características:

- Número de instancias: 178 vinos
- Número de características: 13 variables numéricas continuas
- Etiquetas (target): 3 clases (tipos de vino según su origen)



Uso dataset con k-Means

Aunque el dataset tiene etiquetas, en el ejemplo **K-Means** no las usa (porque es un algoritmo no supervisado). Lo que hace K-Means es agrupar los vinos en k clústeres en función de sus características químicas.

Elementos de sklearn:

- `from sklearn.cluster import KMeans`
- `from sklearn.metrics import silhouette_score`

6-03-Kmeans.ipynb