

DBSCAN – Agrupamiento Basado en Densidad

En esta presentación se explora el algoritmo DBSCAN (Density-Based Spatial Clustering of Applications with Noise), una técnica de agrupamiento basada en densidad. A lo largo de la exposición, se estudia cómo funciona este algoritmo, qué significan los conceptos como la densidad, el radio Eps y el parámetro MinPts, y cómo se definen los puntos núcleo, frontera y ruido.

Jaime Alberto Guzman Luna, Ph.D



¿Qué es DBSCAN?

Agrupamiento Basado en Densidad

DBSCAN agrupa puntos basados en la densidad de los datos.

Robusto al Ruido


Es robusto al ruido (outliers), identificando puntos que no pertenecen a ningún cluster.

Clusters Arbitrarios


Identifica clusters de forma arbitraria, sin asumir una forma específica.

No requiere K



No requiere especificar el número de cluster predefinido a los usuarios



DBSCAN: tres conceptos claves



DBSCAN: Puntos Núcleo, Frontera y Ruido



Eps = 8, MinPts = 5

Puntos núcleos (core):

son puntos que tienen al menos un número mínimo de otros puntos (MinPts) dentro de una distancia específica (ϵ o épsilon). Se conocen también como **centrales**.

Puntos fronterizos (border):

son puntos que están dentro de la distancia ϵ de un punto núcleo pero que no tienen MinPts vecinos.

Puntos de ruido (noise):

Son puntos que no son ni centrales ni frontera. No están lo suficientemente cerca de ningún grupo como para ser incluidos.

DBSCAN utiliza dos parámetros principales:

1



Épsilon (ϵ)

La distancia máxima entre dos puntos para que se consideren vecinos.


2

MinPts

El número mínimo de puntos necesarios para formar una región densa.



1. Punto **x** → **Core Point (Punto núcleo)**
 - Dentro de su vecindario definido por ϵ (epsilon) existen al menos MinPts puntos.
 - Se encuentra en una región suficientemente densa.
2. Punto **y** → **Border Point (Punto frontera)**
 - Está dentro del vecindario ϵ de un punto núcleo.
 - Pero por sí mismo NO tiene suficientes vecinos para cumplir MinPts.
3. Punto **z** → **Noise Point / Outlier (Ruido o atípico)**
 - No pertenece al vecindario denso de ningún punto núcleo.
 - No cumple la condición de densidad mínima.



Puntos Conectados por Densidad





Borde de densidad

Se asigna a un punto **borde** (p_1) que está dentro de una distancia **Epsilon** entre dos puntos **núcleo** q y p .




Conectado por densidad

Un punto p está **conectado por densidad** a un punto q si existe un **camino de puntos borde de densidad** desde p hasta q .



El Concepto de "Puntos Conectados por Densidad" en DBSCAN es uno de los conceptos MÁS IMPORTANTES porque es el mecanismo que el algoritmo usa para decidir:

- ✓ qué puntos pertenecen al mismo clúster
- ✓ cómo expandir un clúster
- ✓ cómo detectar formas complejas.




¿Cómo funciona DBSCAN?

1

Selección de parámetros

- Eps (ϵ) y MinPts:



2

Seleccione un punto de partida


- El algoritmo comienza con un punto arbitrario no visitado en el conjunto de datos.

3

Examinar el vecindario

- Recupera todos los puntos dentro de la distancia ϵ del punto de inicio.
- Si el número de puntos vecinos es menor que **MinPts**, el punto se etiqueta como **ruido** (por ahora).
- Si hay al menos **MinPts** dentro de una distancia ϵ , el punto se marca como **punto central** y se forma un nuevo grupo.

¿Cómo funciona DBSCAN?



4

Expandir el clúster

- Todos los vecinos del punto central se agregan al clúster.
- Para cada uno de estos vecinos:
 - Si es un punto central, sus vecinos se agregan al clúster de forma recursiva.
 - Si no es un punto central, se marca como **punto fronterizo** (border) y la expansión se detiene.

5

Repita el proceso


- El algoritmo se mueve al siguiente punto no visitado en el conjunto de datos.
- Los pasos 3 y 4 se repiten hasta que se hayan visitado todos los puntos.

6

Finalizar clústeres

- Una vez procesados todos los puntos, el algoritmo identifica todos los clústeres.
- Los puntos inicialmente etiquetados como **ruido** ahora podrían ser **puntos fronterizos** si se encuentran dentro de una distancia ϵ de un **punto central**.

Selección de parámetros DBSCAN



ϵ (Epsilon)

Tamaño de la vecindad.

- Si ϵ es muy **pequeño**, se detectan **muchos outliers** y pocos clusters.
- Si ϵ es muy **grande**, se forman **clusters muy grandes** y se pierde la precisión.

MinPts

Cantidad mínima de puntos vecinos.

- Un valor **bajo** hace que se formen muchos clusters pequeños y se acepten más puntos como núcleo.
- Un valor **alto** puede hacer que muchos puntos se consideren ruido.


¿Cómo elegirlos?

- Para **seleccionar ϵ** , se puede usar el conocimiento del dominio o emplear un gráfico de K-distancia, donde el valor óptimo se encuentra en el "codo" de la curva (ver archivo ejemplo al final).
- En cuanto a **MinPts**, una regla general es establecerlo como **el doble del número de características del conjunto de datos**. Una segunda regla es **el número de características + 1**. Sin embargo, si los datos contienen mucho ruido o se desea detectar grupos más pequeños, MinPts puede reducirse. Para conjuntos de datos grandes, se recomienda aumentarlo para evitar demasiados clústeres pequeños.

Ventajas y Desventajas de DBSCAN

Ventajas


- No requiere predefinir número de clusters.
- Robusto al ruido.



Desventajas

- Sensible a la elección de parámetros.
- Dificultad con densidades variables.

DBSCAN es una herramienta poderosa. Es útil para el agrupamiento de datos complejos.



Ejemplo Práctico de Aplicación: Detalles



Dominio

Se usa el **Iris Dataset** de sklearn. Es un conjunto de datos relacionado con las variedades de la flor Iris que contiene 150 muestras.

Características:

- Número de instancias: 150 muestras
- Número de características: 4 variables numéricas continuas
- Etiquetas (target): 3 clases (tipos de flor Iris)



Uso dataset con k-Means

Aunque el dataset tiene etiquetas, en el ejemplo **dbscan** no las usa (porque es un algoritmo no supervisado). Lo que hace dbscan es agrupar las muestras en función de los parámetros Eps (ϵ) y MinPts.

Elementos de sklearn:

- `from sklearn.cluster import DBSCAN`
- `from sklearn.neighbors import NearestNeighbors`

6-04-DBSCAN.ipynb