

Universidad Nacional de Colombia



Introducción a la Inteligencia Artificial




Aprendizaje No Supervisado

Profesor: Jaime Alberto Guzman Luna

2026-1

1-. Análisis de Métricas de Clasificación en un Caso de Detección de Culpabilidad



Objetivo educativo: Analizar el desempeño de modelos de clasificación binaria en un contexto de detección de culpabilidad, interpretando métricas como precisión, recall, F1-score, accuracy, AUC-ROC y la curva PR, y comprendiendo cómo su elección depende del impacto de los errores en diferentes situaciones, especialmente cuando las clases están desbalanceadas o los errores tienen costos distintos.

Imagina que eres un detective participando en un concurso donde debes predecir si un sospechoso es culpable o inocente. Después de realizar las predicciones, el organizador te proporciona una matriz de confusión que muestra cuántos inocentes fueron correctamente identificados como inocentes (verdaderos positivos), cuántos inocentes fueron incorrectamente señalados como culpables (falsos negativos), cuántos culpables fueron correctamente identificados (verdaderos negativos) y cuántos culpables no fueron detectados (falsos positivos).

A continuación puedes encontrar el notebook con la actividad:

[Actividad Google Colab](#)

Después de completar el notebook, responde las siguientes preguntas:

- Supón que tu modelo tiene una **precisión de 0.95** pero un **recall de 0.40**. ¿Cómo interpretas esto en términos de desempeño del detective? ¿Qué dice esto sobre los sospechosos culpables?

- Realice el siguiente cálculo a mano de las cuatro métricas vistas en clase, determine la cantidad de Verdaderos Positivos, Verdaderos Negativos, Falsos Positivos, Falsos Negativos para cada clase y calcula el Accuracy global.

Etiqueta	Predicción A	Predicción B	Predicción C
Real A	30	5	10
Real B	3	25	12
Real C	2	6	27

2-. Uso del Algoritmo K-Means para Identificar Grupos en un Conjunto de Datos



Objetivo educativo: Comprender el funcionamiento del algoritmo K-Means para agrupar datos en función de su similitud, analizando cómo la distribución de clases, la distancia entre puntos y la elección del número de clústers (K) afectan la calidad y confiabilidad del agrupamiento en escenarios con estructuras complejas o clases desbalanceadas.

Imagina que estás en una aldea llamada **Aldea Datos**, donde los habitantes no saben a qué grupo pertenecen, pero quieren organizarse en comunidades según sus similitudes: cómo viven, qué hacen, o cómo piensan. Un día, llegan unos sabios con una idea para ordenar la aldea: decidirán formar **K comunidades**, pero no saben aún cómo agrupar a los habitantes. Así que al principio, eligen **K puntos al azar** en el mapa de la aldea: esos serán los **centros temporales** de cada comunidad.

Cada habitante de la aldea camina hacia el centro más cercano y se **asigna a ese grupo**. Una vez todos se han agrupado, los sabios recalculan dónde debería estar el **verdadero centro de cada grupo**, tomando el promedio de las posiciones de todos los habitantes en cada comunidad. Entonces, los nuevos centros se actualizan, y cada habitante **revisa si hay un centro más cercano** que el anterior. Si lo hay, cambia de grupo. Este proceso se repite una y otra vez: asignar a los centros más cercanos y recalcular los centros con base en los miembros actuales del grupo.

Finalmente, cuando ya nadie quiere cambiar de comunidad, los sabios dicen: “Hemos encontrado las agrupaciones más naturales para Aldea Datos”.

[Actividad Google Colab](#)

Después de completar el notebook, responda las siguientes preguntas:

- Utilice la siguiente hoja de excel para realizar una actualización de los centroides en el contexto del algoritmo de KNN.

Algunas fórmulas de excel que son útiles para lograr esto son:

- **RAÍZ()**: Permite el cálculo de la raíz cuadrada.
- **[PROMEDIO.SI\(\)](#)** Permite realizar el promedio basado en condicionales.

Encontrará 3 hojas dentro del excel:


Datos: Hace las veces de dataset, es decir, contiene la información que se utilizará para ajustar el algoritmo. Deben completar la columna cluster que corresponde a que cluster se asigna cada dato.

Centroides: Contiene los centroides iniciales que servirán para calcular la distancia de cada dato a este punto.

Distancias: Distancias que hay entre un punto y cada cluster y determinarán a cual cluster pertenece.

[Hoja de Cálculo](#)

3-. Identificación de Agrupamientos Basados en Densidad con el Algoritmo DBSCAN



Objetivo educativo: Aplicar el algoritmo DBSCAN para identificar agrupaciones de datos basadas en densidad sin necesidad de definir un número de clústers previamente, comprendiendo cómo influyen los parámetros epsilon y la distancia mínima en la detección de zonas densas, el manejo de ruido y la identificación de estructuras con formas y densidades variables.

Imagina que eres un analista que vive en el Distrito de Análisis, donde cada edificio representa un dato. Tu objetivo es identificar zonas de alta concentración de edificios, sin saber cuántas zonas existen de antemano ni qué tan grandes son.

El distrito es diverso: algunas áreas están muy congestionadas, con edificios altos y cercanos entre sí, mientras que otras zonas son más dispersas, con pocos edificios que están muy alejados unos de otros. Para resolver el problema, decides usar un enfoque basado en densidad: quieres encontrar aquellos grupos de edificios que están cercanos y forman zonas de alta densidad.

El desafío consiste en encontrar estas zonas densas sin asumir un número específico de grupos. Además, necesitas asegurarte de que las zonas menos densas o los edificios aislados no sean incluidos en ninguna zona, ya que no forman parte de ninguna agrupación significativa. Así, buscas una manera de identificar grupos que se destaquen por su concentración, sin forzar una estructura rígida de clasificación. Aquí es donde DBScan, con su capacidad para descubrir agrupaciones basadas en densidad, se convierte en la herramienta ideal.

[Actividad Google Colab](#)

Después de completar el notebook, responda las siguientes preguntas:

- En el Distrito de Análisis, algunos edificios están tan juntos que forman una gran zona densa, mientras que otros están agrupados en pequeñas áreas dispersas. ¿Por qué DBSCAN puede detectar correctamente estas formas de agrupación, mientras que otros algoritmos como K-Means podrían fallar en representarlas adecuadamente?
- Durante tu análisis, DBSCAN clasifica varios edificios como “ruido”. ¿Qué representa este ruido en términos de los datos originales, y por qué puede ser útil conservarlo en lugar de eliminarlo inmediatamente?